

**UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO
CENTRO DE CIÊNCIAS EXATAS, NATURAIS E DA SAÚDE
GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO**

FABRÍCIO MEDEIROS TOZO

**CLASSIFICAÇÃO DE IMAGENS COM REDE NEURAL
CONVOLUCIONAL**

ALEGRE

2024

FABRÍCIO MEDEIROS TOZO

CLASSIFICAÇÃO DE IMAGENS COM REDE NEURAL CONVOLUCIONAL

Este documento tem o objetivo de relatar as etapas de desenvolvimento do primeiro trabalho da disciplina de Aprendizado de Máquina.

Professor: Jacson Rodrigues Correia da Silva

ALEGRE
2024

SUMÁRIO

Sumário	2
1 INTRODUÇÃO	3
2 OBJETIVOS	4
2.0.1 OBJETIVOS ESPECÍFICOS	4
3 50 CLASSES DO DATASET FLOWERS102	5
4 PRÉ PROCESSAMENTO DOS DADOS E SELEÇÃO DE HYPER- PARAMETROS	6
5 SELEÇÃO DE HYPERPARAMETROS E DATA AUGMENTATIONS	7
6 FASE DE TREINO, TESTE E VALIDAÇÃO	8
7 ANÁLISE DA ACURÁCIA E CURVA DE APRENDIZADO	10
8 DESCRIÇÃO DO APRENDIZADO COM O TRABALHO	14
9 REFERENCIAS	15

1 INTRODUÇÃO

Este relatório tem como objetivo descrever as etapas e resultados obtidos durante o desenvolvimento de um classificador de imagens utilizando redes neurais convolucionais.

O trabalho foi realizado utilizando o dataset Flowers102, que contém 102 categorias diferentes de flores.

O foco foi selecionar um subconjunto de 50 classes e aplicar um modelo pré-treinado ResNet18 para realizar a classificação das imagens, utilizando técnicas de Cross-Validation e ajuste de hiperparâmetros.

Além disso, serão descritas as dificuldades encontradas, os resultados obtidos, e uma análise crítica sobre o aprendizado adquirido ao longo do processo.

Palavras-chave: Aprendizado supervisionado; Classificação; Aprendizado Profundo; Redes Neurais Artificiais;

2 OBJETIVOS

2.0.1 OBJETIVOS ESPECÍFICOS

- Selecionar, aleatoriamente, 50 classes do dataset Flowers102;
- Pré processamento dos dados;
- Seleção de hyperparametros;
- Fase de Treino, Teste e Validação;
- Analise da acurácia e curva de aprendizado;
- Descrição do aprendizado com o trabalho;
- Referencias;

3 50 CLASSES DO DATASET FLOWERS102

A etapa da separação dos dados consiste majoritariamente em escolher as imagens a serem usadas como entrada para o treinamento.

Usamos nessa pesquisa as seguintes 50 classes aleatórias.

```
1 def filter_classes(dataset, selected_classes):
2     indices = [idx for idx, (_, label) in enumerate(dataset)
3                 if label in selected_classes]
4     return Subset(dataset, indices)
5
6     [ 7, 18, 64, 14, 8, 47, 94, 84, 30, 74, 27, 70, 33, 1, 28, 95, 32,
7      72, 77, 60, 55, 79, 11, 54, 59, 29, 51, 43, 71, 5, 92, 53, 34, 2,
8      48, 36, 9, 39, 42, 15, 17, 86, 45, 93, 62, 49, 46, 82, 68, 21]
```

4 PRÉ PROCESSAMENTO DOS DADOS E SELEÇÃO DE HYPERPARAMETROS

Com as Classes selecionadas adicionamos uma nova classe para remapear os índices.

```

1 class MappedDataset(Dataset):
2     def __init__(self, subset, class_mapping):
3         self.subset = subset
4         self.class_mapping = class_mapping
5
6     def __len__(self):
7         return len(self.subset)
8
9     def __getitem__(self, idx):
10        img, label = self.subset[idx]
11        label = self.class_mapping.get(label, -1)
12        return img, label

```

```

1 def prepare_data(self, data_transform, train_dataset, val_dataset,
2 test_dataset, selected_classes):
3     # Mapear classes para [0, 49]
4     self.class_mapping = {original: new for new, original in enumerate(
5         selected_classes)}
6
7     # Filtragem e mapeamento dos datasets
8     train_subset = self.filter_classes(train_dataset, selected_classes)
9     val_subset = self.filter_classes(val_dataset, selected_classes)
10    test_subset = self.filter_classes(test_dataset, selected_classes)
11
12    train_mapped = self.MappedDataset(train_subset, self.class_mapping)
13    val_mapped = self.MappedDataset(val_subset, self.class_mapping)
14    test_mapped = self.MappedDataset(test_subset, self.class_mapping)
15
16    # DataLoaders
17    self.train_loader = DataLoader(train_mapped, batch_size=self.
18        batch_size, shuffle=True)
19    self.val_loader = DataLoader(val_mapped, batch_size=self.batch_size,
20        shuffle=False)
21    self.test_loader = DataLoader(test_mapped, batch_size=self.
22        batch_size, shuffle=False)

```

5 SELEÇÃO DE HYPERPARAMETROS E DATA AUGMENTATIONS

```

1  def create_model(self):
2      model = models.resnet18()
3      num_ftrs = model.fc.in_features
4      model.fc = nn.Sequential(
5          nn.Linear(num_ftrs, self.num_classes)
6      )
7      return model.to(device)

```

Data Augmentations utilizados

```

1  data_transform = transforms.Compose([
2      transforms.Resize((224, 224)),
3      transforms.RandomHorizontalFlip(),
4      transforms.RandomRotation(10),
5      transforms.ColorJitter(brightness=0.3, contrast=0.3),
6      transforms.RandomAffine(degrees=30, shear=20),
7      transforms.ToTensor(),
8      transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224,
9          0.225])
10 ])
11 train_dataset = datasets.Flowers102(root=r'E:\Dataset_torchvision',
12     split='test', download=True, transform=data_transform)
13 val_dataset = datasets.Flowers102(root=r'E:\Dataset_torchvision', split=
14     'val', download=True, transform=data_transform)
15 test_dataset = datasets.Flowers102(root=r'E:\Dataset_torchvision', split
16     ='train', download=True, transform=data_transform)

```

Melhores Hyperparametros encontrados

```

1  criterion = nn.CrossEntropyLoss()
2  optimizer = optim.Adam()
3  num_classes=50
4  batch_size=32
5  lr= 0.001 ~~ lr= 0.0001
6  epochs=21

```

Insights: Learning Rate = 0.001 apresentou melhor resultado nos primeiros 2 treinos, entrando na terceira fase de treino temos melhor resultados usando Learning Rate scheduler entre 0.001 e 0.00001.

6 FASE DE TREINO, TESTE E VALIDAÇÃO

Nesta fase já com todas as imagens selecionadas, mascaras criadas e organizadas podemos entrar na fase de treino e teste.

```

1 def train(self):
2     print("Starting training...")
3     train_losses = []
4     val_accuracies = []
5     val_f1_scores = []
6
7     for epoch in range(self.epochs):
8         self.model.train()
9         running_loss = 0.0
10        for inputs, labels in self.train_loader:
11            inputs, labels = inputs.to(device), labels.to(device)
12            self.optimizer.zero_grad()
13            outputs = self.model(inputs)
14            loss = self.criterion(outputs, labels)
15            loss.backward()
16            self.optimizer.step()
17            running_loss += loss.item() * inputs.size(0)
18
19        epoch_loss = running_loss / len(self.train_loader.dataset)
20        train_losses.append(epoch_loss)
21        print(f'Epoch{epoch+1}/{self.epochs}, Loss: {epoch_loss:.4f}')
22
23        #Validacao apos cada epoca
24        val_accuracy, val_f1 = self.validate(self.val_loader)
25        val_accuracies.append(val_accuracy)
26        val_f1_scores.append(val_f1)
27
28    print("Training complete.")
29    return train_losses, val_accuracies, val_f1_scores

```

```
1 def validate(self, loader):
2     self.model.eval()
3     correct = 0
4     total = 0
5     all_labels = []
6     all_predictions = []
7
8     with torch.no_grad():
9         for inputs, labels in loader:
10             inputs, labels = inputs.to(device), labels.to(device)
11             outputs = self.model(inputs)
12             _, predicted = torch.max(outputs, 1)
13             total += labels.size(0)
14             correct += (predicted == labels).sum().item()
15             all_labels.extend(labels.cpu().numpy())
16             all_predictions.extend(predicted.cpu().numpy())
17
18     accuracy = accuracy_score(all_labels, all_predictions) * 100
19     f1 = f1_score(all_labels, all_predictions, average='macro')
20     print(f'Validation Accuracy: {accuracy:.2f}%, Macro F1-Score: {f1:.4f}')
21     return accuracy, f1
22
23 # Funcao para testar o modelo com o conjunto de teste
24 def test(self):
25     print("Testing model on test dataset...")
26     return self.validate(self.test_loader)
```

7 ANALISE DA ACURÁCIA E CURVA DE APRENDIZADO

```

1 Using device: cuda
2 Starting training...
3 Epoch 1/21, Loss: 3.0818
4 Validation Accuracy: 17.80%, Macro F1-Score: 0.1153
5 Epoch 2/21, Loss: 2.2746
6 Validation Accuracy: 32.60%, Macro F1-Score: 0.2693
7 Epoch 3/21, Loss: 1.9799
8 Validation Accuracy: 40.80%, Macro F1-Score: 0.3722
9 Epoch 4/21, Loss: 1.7698
10 Validation Accuracy: 43.00%, Macro F1-Score: 0.3906
11 Epoch 5/21, Loss: 1.5682
12 Validation Accuracy: 45.40%, Macro F1-Score: 0.4136
13 Epoch 6/21, Loss: 1.4402
14 Validation Accuracy: 52.00%, Macro F1-Score: 0.4902
15 Epoch 7/21, Loss: 1.3238
16 Validation Accuracy: 56.00%, Macro F1-Score: 0.5307
17 Epoch 8/21, Loss: 1.1942
18 Validation Accuracy: 52.00%, Macro F1-Score: 0.5013
19 Epoch 9/21, Loss: 1.1342
20 Validation Accuracy: 58.80%, Macro F1-Score: 0.5625
21 Epoch 10/21, Loss: 1.0470
22 Validation Accuracy: 57.80%, Macro F1-Score: 0.5557
23 Epoch 11/21, Loss: 0.9732
24 Validation Accuracy: 56.80%, Macro F1-Score: 0.5420
25 Epoch 12/21, Loss: 0.9217
26 Validation Accuracy: 62.60%, Macro F1-Score: 0.6070
27 Epoch 13/21, Loss: 0.8037
28 Validation Accuracy: 64.60%, Macro F1-Score: 0.6167
29 Epoch 14/21, Loss: 0.7640
30 Validation Accuracy: 65.80%, Macro F1-Score: 0.6385
31 Epoch 15/21, Loss: 0.7526
32 Validation Accuracy: 68.80%, Macro F1-Score: 0.6688
33 Epoch 16/21, Loss: 0.6704
34 Validation Accuracy: 71.20%, Macro F1-Score: 0.6988
35 Epoch 17/21, Loss: 0.6542
36 Validation Accuracy: 69.80%, Macro F1-Score: 0.6790
37 Epoch 18/21, Loss: 0.5910
38 Validation Accuracy: 70.40%, Macro F1-Score: 0.6884
39 Epoch 19/21, Loss: 0.5793
40 Validation Accuracy: 71.60%, Macro F1-Score: 0.7095
41 Epoch 20/21, Loss: 0.5633
42 Validation Accuracy: 66.60%, Macro F1-Score: 0.6591
43 Epoch 21/21, Loss: 0.4815
44 Validation Accuracy: 76.80%, Macro F1-Score: 0.7602
45 Training complete.

```

```
1 Using device: cuda
2 Starting training...
3 Epoch 1/21, Loss: 0.5201
4 Validation Accuracy: 75.00%, Macro F1-Score: 0.7482
5 Epoch 2/21, Loss: 0.4587
6 Validation Accuracy: 72.00%, Macro F1-Score: 0.7213
7 Epoch 3/21, Loss: 0.4303
8 Validation Accuracy: 71.60%, Macro F1-Score: 0.7126
9 Epoch 4/21, Loss: 0.4071
10 Validation Accuracy: 76.60%, Macro F1-Score: 0.7547
11 Epoch 5/21, Loss: 0.4069
12 Validation Accuracy: 71.60%, Macro F1-Score: 0.7076
13 Epoch 6/21, Loss: 0.3806
14 Validation Accuracy: 77.60%, Macro F1-Score: 0.7739
15 Epoch 7/21, Loss: 0.3589
16 Validation Accuracy: 78.60%, Macro F1-Score: 0.7788
17 Epoch 8/21, Loss: 0.3313
18 Validation Accuracy: 75.00%, Macro F1-Score: 0.7384
19 Epoch 9/21, Loss: 0.3125
20 Validation Accuracy: 79.00%, Macro F1-Score: 0.7858
21 Epoch 10/21, Loss: 0.2959
22 Validation Accuracy: 73.20%, Macro F1-Score: 0.7296
23 Epoch 11/21, Loss: 0.2763
24 Validation Accuracy: 79.40%, Macro F1-Score: 0.7942
25 Epoch 12/21, Loss: 0.2714
26 Validation Accuracy: 78.00%, Macro F1-Score: 0.7770
27 Epoch 13/21, Loss: 0.2592
28 Validation Accuracy: 77.20%, Macro F1-Score: 0.7721
29 Epoch 14/21, Loss: 0.2767
30 Validation Accuracy: 79.80%, Macro F1-Score: 0.7898
31 Epoch 15/21, Loss: 0.2232
32 Validation Accuracy: 81.60%, Macro F1-Score: 0.8159
33 Epoch 16/21, Loss: 0.2143
34 Validation Accuracy: 78.00%, Macro F1-Score: 0.7734
35 Epoch 17/21, Loss: 0.2322
36 Validation Accuracy: 77.80%, Macro F1-Score: 0.7756
37 Epoch 18/21, Loss: 0.2362
38 Validation Accuracy: 79.00%, Macro F1-Score: 0.7810
39 Epoch 19/21, Loss: 0.1946
40 Validation Accuracy: 80.40%, Macro F1-Score: 0.7954
41 Epoch 20/21, Loss: 0.1688
42 Validation Accuracy: 79.80%, Macro F1-Score: 0.7922
43 Epoch 21/21, Loss: 0.1570
44 Validation Accuracy: 81.00%, Macro F1-Score: 0.8042
45 Training complete.
```

```
1 Using device: cuda
2 Starting training...
3 Epoch 1/21, Loss: 0.2017
4 Validation Accuracy: 78.80%, Macro F1-Score: 0.7786
5 Epoch 2/21, Loss: 0.1699
6 Validation Accuracy: 80.60%, Macro F1-Score: 0.7987
7 Epoch 3/21, Loss: 0.1950
8 Validation Accuracy: 80.80%, Macro F1-Score: 0.8042
9 Epoch 4/21, Loss: 0.1722
10 Validation Accuracy: 78.00%, Macro F1-Score: 0.7662
11 Epoch 5/21, Loss: 0.1961
12 Validation Accuracy: 82.00%, Macro F1-Score: 0.8184
13 Epoch 6/21, Loss: 0.1617
14 Validation Accuracy: 83.40%, Macro F1-Score: 0.8291
15 Epoch 7/21, Loss: 0.1470
16 Validation Accuracy: 84.20%, Macro F1-Score: 0.8369
17 Epoch 8/21, Loss: 0.1448
18 Validation Accuracy: 82.80%, Macro F1-Score: 0.8249
19 Epoch 9/21, Loss: 0.1584
20 Validation Accuracy: 79.80%, Macro F1-Score: 0.7892
21 Epoch 10/21, Loss: 0.1263
22 Validation Accuracy: 84.20%, Macro F1-Score: 0.8386
23 Epoch 11/21, Loss: 0.1052
24 Validation Accuracy: 81.60%, Macro F1-Score: 0.8123
25 Epoch 12/21, Loss: 0.1116
26 Validation Accuracy: 82.20%, Macro F1-Score: 0.8149
27 Epoch 13/21, Loss: 0.1565
28 Validation Accuracy: 83.20%, Macro F1-Score: 0.8224
29 Epoch 14/21, Loss: 0.0906
30 Validation Accuracy: 83.00%, Macro F1-Score: 0.8179
31 Epoch 15/21, Loss: 0.0931
32 Validation Accuracy: 81.40%, Macro F1-Score: 0.8092
33 Epoch 16/21, Loss: 0.1244
34 Validation Accuracy: 82.60%, Macro F1-Score: 0.8233
35 Epoch 17/21, Loss: 0.1068
36 Validation Accuracy: 83.60%, Macro F1-Score: 0.8311
37 Epoch 18/21, Loss: 0.0935
38 Validation Accuracy: 80.60%, Macro F1-Score: 0.8021
39 Epoch 19/21, Loss: 0.1039
40 Validation Accuracy: 82.60%, Macro F1-Score: 0.8237
41 Epoch 20/21, Loss: 0.1604
42 Validation Accuracy: 80.20%, Macro F1-Score: 0.7973
43 Epoch 21/21, Loss: 0.1296
44 Validation Accuracy: 83.40%, Macro F1-Score: 0.8221
45 Training complete.
```

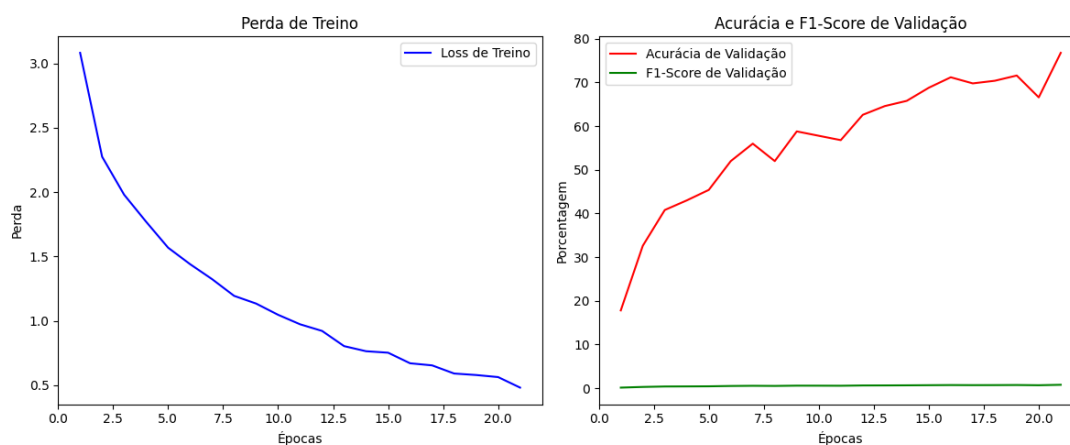


Figura 1 – Primeira fase de treino

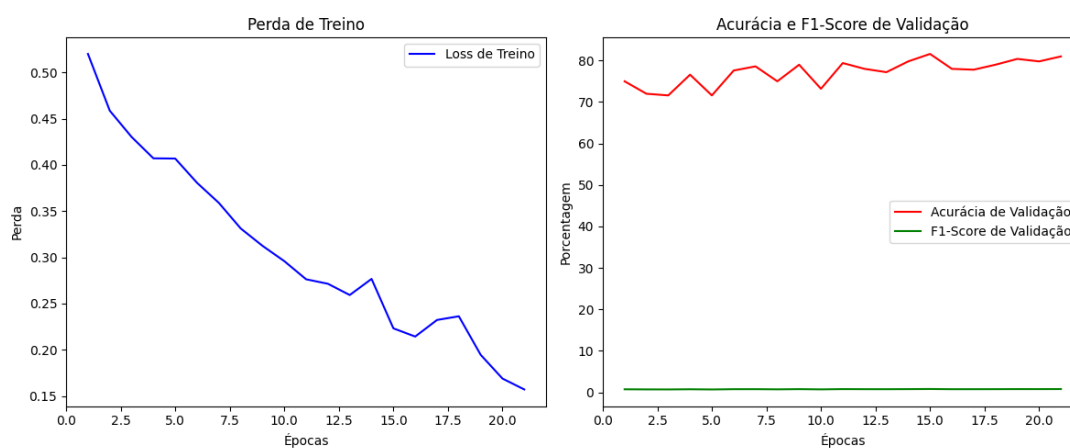


Figura 2 – Segunda Fase de Treino

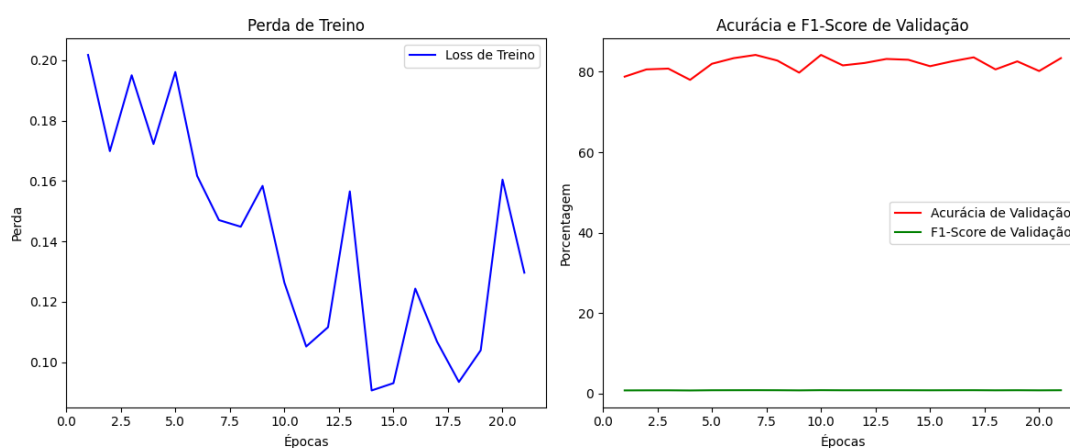


Figura 3 – Terceira Fase de Treino

8 DESCRIÇÃO DO APRENDIZADO COM O TRABALHO

Foi realizado treino de 2 modelos, o primeiro com Dropout(0.5) e o segundo que apresentou melhor resultado sem o uso de Dropout.

Outro ponto que foi observado com uma grande melhora na avaliação foi o uso de data transform informados, onde tivemos uma grande melhora a avaliação do modelo.

Descrição das dificuldades: Grande parte do desafio foi a separação dos dados de treino e a filtragem das classes para o treino, ea adaptação dos dados e camadas de saída do modelo para as 50 classes selecionadas.

9 REFERENCIAS

<https://github.com/FabricioMT/Trabalho-CNN>

<https://pytorch.org/vision/0.18/generated/torchvision.datasets.Flowers102.html>

<https://pytorch.org>

<https://scikit-learn.org>